AI: A Guide for Thinking Humans

章节抽查与 AI 里程碑手册

本手册围绕 Melanie Mitchell 的 Artificial Intelligence: A Guide for Thinking Humans 第 1、2、6、7、8 章组织，后半部分汇总书中其他章节的重要里程碑和案例。每道学生题后紧跟教师参考答案。

双语使用说明 / Bilingual note： 下文的英文关键句是便于课堂讲解的英文概括，与旁边的中文表达同一意思；它们不是原书的逐字引文。核心术语第一次出现及术语表均给出中文与英文。

四次章节抽查安排（每次 70 分钟）

学生已用约一个月详细阅读本书。以下四次课直接使用本讲义的概念说明、学生题目和书中案例；每道题后的参考答案用于反馈，不作为学生背诵材料。附录的 NOAI B 区补充考点暂不纳入这四次抽查。

次数	对应讲义内容	当堂核心任务
第 1 次	第 1 章概念、第 2 章训练流程图及两章学生题	比较 GPS 与感知机；解释损失、反向传播、梯度下降和学习率如何调整权重与偏置。
第 2 次	第 6 章学生题、全书里程碑表中的视觉与长尾案例	区分数据集内准确率、泛化和现实鲁棒性；用撒盐线、沙袋、背景捷径或对抗样本支持判断。
第 3 次	第 7 章概念与学生题、ACLU 人脸识别案例	分析群体偏差、不可解释性、隐私、复核和责任；给出具体应对措施。
第 4 次	Rosie 的 Q-learning、第 8 章学生题、AlphaGo 延伸题	解释奖励如何影响较早动作、探索与利用；比较机器人与围棋任务的边界。

每次 70 分钟的使用方式： 10 分钟查看本次对应部分与书中证据；25 分钟独立回答对应学生题；20 分钟讲解、互相追问“这个例子说明什么、不能说明什么”；15 分钟根据讨论和教师反馈修订答案。里程碑表用于查找证据，不要求逐项记忆年份。

第一部分：按四次抽查学习

请按“方法或机制 - 书中例子 - 能说明什么 - 不能说明什么”作答。每章先看概念解释，再独立回答紧随其后的学生题。每道题后紧跟参考答案，课堂抽查时先遮住答案独立作答。

第 1 次：早期 AI 与神经网络（第 1、2 章）

第 1 章概念：四种思路

它们不是四个完全平行、互相排斥的类别。符号主义（symbolic AI）与次符号主义（subsymbolic AI）是两种 AI 表示路线；连接主义（connectionism）是次符号主义中受大脑启发的重要路线；行为主义（behaviorism）来自心理学，影响了人们对学习和反馈的理解。

关键句 / Key statement： 连接主义属于次符号主义的重要路线，行为主义则是关于学习的心理学观点。 / Connectionism is a major subsymbolic approach, whereas behaviorism is a psychological account of learning.

思路	关注什么	书中例子	关系与局限
符号主义（symbolic AI）	用人能读懂的符号表示概念，再用明确规则操作这些符号。	General Problem Solver（GPS）：把状态、目标、操作和规则写清，再搜索“传教士与食人族”问题的解。	规则明确时容易追踪推理；规则之外的情况和常识难以穷举。
次符号主义（subsymbolic AI）	不把所有知识都写成人类可读规则，而通过数值计算和数据学习模式。	感知机（perceptron）、现代神经网络（neural networks）。	是与符号路线相对的宽泛说法；通常适合感知任务，但内部数值表示不容易解释。
连接主义（connectionism）	认为知识分布在许多处理单元及其带权连接中；受大脑神经连接启发。	感知机、多层神经网络，以及 1980 年代的 connectionist networks。	是次符号主义的一条主要路线，不是与次符号主义并列的另一大类。
行为主义（behaviorism）	研究行为怎样受环境、训练和奖惩影响，重视可观察的刺激、反应和条件作用。	Skinner 用强化训练动物；Rosenblatt 借鉴条件作用，让感知机根据正确或错误反馈调整。	是心理学学习观，不是网络结构。监督学习（supervised learning）的反馈思想和强化学习（reinforcement learning）的奖励有历史联系，但不能把它们简单等同于行为主义。

快速辨认： 符号主义问“规则和概念怎样写出来”；次符号主义问“数值系统怎样从数据学出模式”；连接主义问“知识怎样分布在神经单元的连接中”；行为主义问“反馈和奖惩怎样改变行为”。

第 1 章：四种思路与早期 AI

区分符号主义、次符号主义、连接主义和行为主义。GPS 与感知机分别体现什么？行为主义的反馈观如何影响感知机学习？

作答核心句 / Answer focus： 四种思路不是四个互斥类别。 / The four approaches are not four mutually exclusive categories.

参考答案

GPS 体现符号主义：人明确写出概念、状态、规则和操作，程序再搜索解法。感知机体现次符号主义和连接主义：它用数值权重表示输入连接的影响，并从例子中调整这些数值。连接主义是次符号 AI 的一种脑启发路线，不是与次符号主义并列的类别。行为主义是心理学关于行为受环境和反馈塑造的观点；Rosenblatt 借鉴 Skinner 的条件作用，把正确/错误反馈用于训练感知机。行为主义不是网络结构，监督学习与强化学习也不能简单等同于行为主义。GPS 规则清楚、推理较可读，但常识难穷举；单层感知机可学习，但能力受限。

关键句 / Key statement： GPS 依赖人写的符号与规则，感知机则从例子中调整连接权重。 / GPS relies on human-written symbols and rules; a perceptron adjusts connection weights from examples.

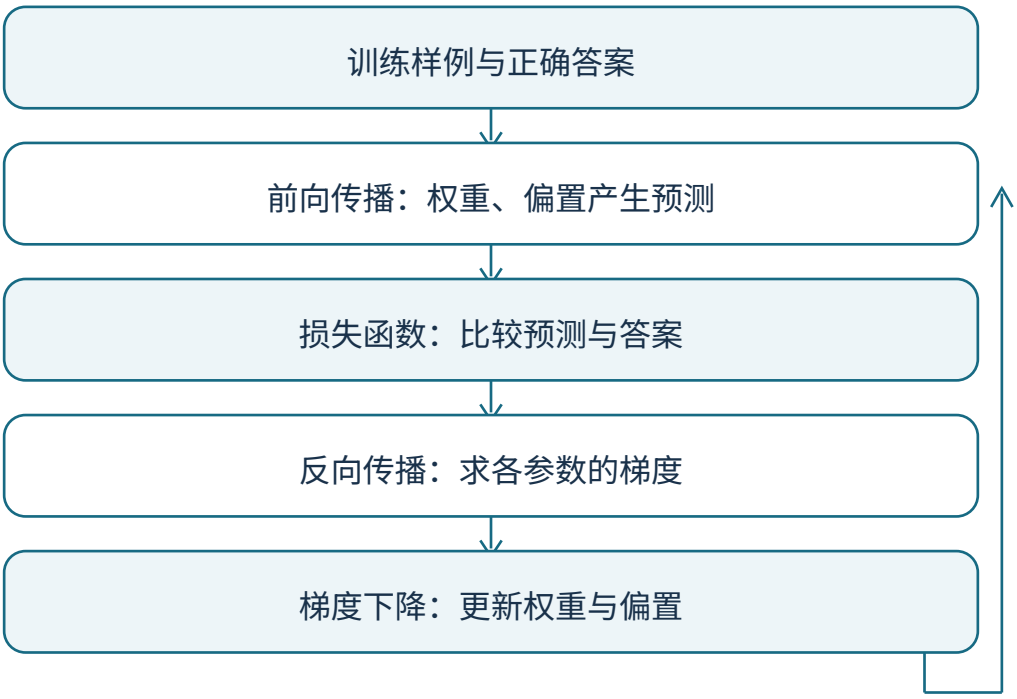
第 2 章概念：网络怎样训练

关键句 / Key statement： 损失函数衡量错误，反向传播计算梯度，梯度下降按学习率更新权重和偏置。 / The loss function measures error; backpropagation computes gradients; gradient descent updates weights and biases using the learning rate.

环节	它回答的问题	对权重和偏置做什么
损失函数（loss function）	预测错了多少?	把预测与正确答案的差异汇总成可比较的数值。它衡量错误大小，但单独不告诉每个参数该往哪边改。
梯度（gradient）	每个参数稍微改变时，损失会怎样变化?	为每个权重（weight）和偏置（bias parameter）提供局部的变化方向与幅度信息。梯度指向损失上升最快的方向。
反向传播（backpropagation）	各层参数分别对错误有多大影响?	从输出层向前传递误差信息，计算每个权重和偏置对应的梯度。
梯度下降（gradient descent）	怎样让损失往下降?	让参数朝梯度的反方向移动，使当前附近的损失减小。权重和偏置都会更新。

环节	它回答的问题	对权重和偏置做什么
学习率（learning rate）	每次移动多大一步？	控制每次参数更新的步幅；不决定方向，方向由梯度提供。

一次训练循环： 箭头表示先后顺序；学习率作用在参数更新这一步。



学习率控制更新步幅；更新后进入下一轮预测

怎样调整权重： 如果某条连接的权重稍微变大就会让损失变大，梯度会记录这一局部关系，梯度下降就把该权重往相反方向调；如果变大能让损失下降，更新方向就相反。权重影响还取决于该连接上的输入信号强弱。

怎样调整偏置： 偏置也有自己的梯度和更新步幅。它整体移动一个神经元的判断基准，不依赖某个输入特征是否特别强；它和权重一样，按梯度指示的方向、由学习率控制步幅来更新。

学习率大小的影响： 太大时，参数可能越过低损失区域，训练震荡甚至发散；太小时，每次只移动一点，训练会很慢，也可能长时间停在不理想的位置。训练时观察损失和验证集表现，帮助选择或调整学习率。

关系总览： 损失函数衡量错多少；梯度描述损失对每个参数的敏感方向和幅度；反向传播负责计算梯度；梯度下降用梯度更新权重和偏置；学习率控制更新幅度。

第 2 章：网络怎样学会识别数字

多层神经网络怎样改进了单层感知机？请解释损失函数、梯度、反向传播、梯度下降和学习率怎样共同调整权重与偏置。为什么识别准确率提升不等于网络已经像人一样理解数字？

作答核心句 / Answer focus： 反向传播算梯度，梯度下降按学习率更新参数。 / Backpropagation computes gradients, and gradient descent updates parameters at a step size set by the learning rate.

参考答案

多层网络增加隐藏层，能组合出更复杂的特征。损失函数把预测与正确答案的差异量化。梯度说明损失对每个权重和偏置在当前位置的变化方向与幅度。反向传播从输出往前计算这些梯度；梯度下降让参数朝损失下降的方向更新；学习率控制每次更新的步幅。太大可能越过低损失区域、震荡或发散；太小则训练缓慢。权重更新方向由它对应的梯度决定，偏置也有自己的梯度；权重影响还受该连接输入信号强弱影响。

书中的手写数字实验使用 60,000 个例子训练、10,000 个新例子测试：单层感知机约答对 80%，含 50 个隐藏单元的网络约 94%。这说明在该测试设置下网络表现更好，不证明它理解数字的含义；作者指出网络参数难以解释。

关键句 / Key statement： 更高的识别准确率不等于像人一样理解数字。 / Better recognition accuracy does not imply human-like understanding of digits.

第 2 次：准确率之外（第 6 章）

阅读本章题目时，利用第二部分里程碑表中的视觉识别、撒盐线、沙袋、背景捷径和对抗样本作证据；区分“测试集高分”“新情境泛化”“现实鲁棒性”。

第 6 章：图像识别的进步与局限

深度学习在图像识别上的进步，解决了早期方法的哪些困难？书中又用哪些例子说明它仍然会出错？

作答核心句 / Answer focus： 数据集内准确率、对新情境的泛化和现实鲁棒性需要分别评估。 / In-distribution accuracy, generalization to new situations, and real-world robustness must be evaluated separately.

参考答案

深度网络能从大量图像中逐层学习有用特征，不必完全依赖人手写识别规则。Google Brain 的猫识别实验，以及 AlexNet 在 2012 年 ImageNet 比赛中的表现，展示了这类方法的进步。但模型可能依赖背景等偶然线索，也可能在模糊、旋转或轻微干扰下失误；它在常见图像上表现好，也不代表它理解了图像的含义或具备常识。这两个成功例子分别见于书中前面的深度学习与视觉章节，第 6 章进一步追问学习的结果有多可靠。

关键句 / Key statement： 测试集高分只说明模型在该数据分布与指标上表现好；它不保证新情境中的泛化（generalization）和现实鲁棒性（robustness）。 / A high test score shows performance on that data distribution and metric; it does not guarantee generalization or robustness in new situations.

第 3 次：可信与伦理（第 7 章）

第 6 章到第 7 章：从错误到后果

第 6 章重点问：模型为什么可能在测试集外出错？第 7 章进一步问：把这种系统用于现实决策时，谁受到影响，怎样发现、解释、纠正错误，并确定责任？下面的局限有跨章联系，但讨论角度不同。

关键句 / Key statement： 测试集的高准确率不等于现实中的可靠与可信。 / High test-set accuracy does not guarantee real-world reliability or trustworthiness.

局限或问题	具体含义	为什么影响信任
长尾情境（long-tail scenarios）与缺少常识（lack of common sense）	罕见道路情境等难以被训练样本穷尽；模型未必理解行为背后的因果和常识。	自动驾驶等系统在少见情境中可能作出危险决定。
偏差（bias）与不公平（unfairness）	训练数据和使用方式可能让不同群体的错误率不同。	总体准确率会掩盖具体人群承担的误认风险。
不可解释性（lack of interpretability；黑箱问题 / black-box problem）	深度网络可以输出判断，但海量数值运算通常不能直接给人可理解的理由；也难确认它是否依赖了错误线索。	更难预测何时会错、追查误判原因、纠错和问责。知道运算步骤不等于理解判断依据。
鲁棒性不足（lack of robustness）	模糊、旋转、环境或数据分布变化后，表现可能显著下降。	常见测试样例上的高分难保证现实场景的稳定表现。
对抗攻击（adversarial attacks）	人为设计输入变化，可诱使模型高置信度误判。	蓄意欺骗与普通环境变化不同，还涉及系统安全。

局限或问题	具体含义	为什么影响信任
隐私（privacy）、使用目的与责任（accountability）	人脸数据可被收集和比对；错误结果可能进入执法等重要决定。	必须讨论何时可以使用、人工复核、申诉渠道和责任归属。
道德判断（moral reasoning）需要情境理解	简单规则不能穷尽“伤害”的含义、因果、他人目标和价值冲突。	机器不能仅凭几条规则可靠地处理现实伦理难题。

不可解释性要单独掌握： 第 7 章的 Show Your Work 指出，即使列出神经网络每一步加减乘除，人也不一定理解它为何认定图片中的对象。可视化特征或标出输入的重要区域能提供线索，却不等于系统已经能给出可靠、完整的人类可理解解释。

关键句 / Key statement： 列出网络的运算步骤，不等于解释它为何作出判断。 / Listing a network’s calculations is not the same as explaining why it made a decision.

机器道德（machine morality）的两个思想实验： 阿西莫夫的机器人三定律（Asimov’s Three Laws of Robotics）按优先级要求机器人：（1）不能伤害人，也不能因不作为让人受伤害；（2）服从人的命令，除非违反第一条；（3）保护自身，除非违反前两条。这是科幻设定，不是可直接部署的安全规范。现实中“伤害”及相互冲突的后果需要情境理解。电车难题（trolley problem）则问：刹车失灵，直行会撞到五人，转向会撞到一人，该怎样选择？它揭示了价值取舍及提问方式对判断的影响；现实自动驾驶还面临不确定信息、更多可选动作和事故预防，不能只靠这道二选一题编程。书中第 7 章讨论的是三定律；后来的“第零定律”不属于本章这段论证。

关键句 / Key statement： 道德规则只有在系统能够理解伤害、因果和情境时才可能可靠地应用。 / Moral rules can be applied reliably only if a system can understand harm, causation, and context.

第 7 章：可信与伦理

为什么模型在测试集上表现好，仍不能直接信任它作出重要现实决定？请以人脸识别及 ACLU 对 Amazon Rekognition 的测试为例，明确解释不可解释性（黑箱问题）；再从长尾风险、偏差、鲁棒性、对抗攻击、隐私、复核与问责中选择至少三项说明。阿西莫夫三定律和电车难题各揭示了机器道德判断的什么困难？

作答核心句 / Answer focus： 不可解释性（lack of interpretability）使我们难以理解和纠正个体判断的错误。 / A lack of interpretability makes it harder to understand and correct errors in individual decisions.

参考答案

高准确率仅反映特定数据和指标下的表现。长尾情境与缺少常识可能使自动驾驶在陌生道路情形下出错；鲁棒性不足使系统在环境变化时失稳，对抗攻击则利用蓄意设计的输入诱使误判。训练数据的偏差可能让部分群体承担更高风险。书中 ACLU 用默认设置测试 Amazon Rekognition：将 535 位国会议员的照片与逮捕数据库比对，28 人被错误匹配；这些误匹配中 21% 涉及非裔议员，而非裔议员约占国会 9%。因此要分别检查群体错误率、使用场景、隐私及误认后果。

不可解释性（黑箱问题）须作为独立局限作答。 网络能输出“是谁”或“是什么”，但即使打印海量运算，也不等于给出了人可以理解的判断依据。若它依靠错误线索，我们可能难以预测失误、纠正模型或解释个体决定。可解释性研究有进展，但不能把网络的计算步骤直接当成完整解释。高风险使用还要设置人工复核、申诉和责任机制。

阿西莫夫的三定律依次要求避免伤害人（包括不作为造成的伤害）、服从不违反第一条的人类命令、在不违反前两条时保护自己。规则看似清楚，实际却需要先理解“伤害”、因果和冲突。电车难题设定直行撞五人、转向撞一人，凸显价值取舍；书中也说明提问方式会影响人们的判断。这些思想实验能引出机器道德讨论，却不能替代对真实系统的安全设计和社会治理。

关键句 / Key statement： 不可解释性（lack of interpretability）是独立的可信度局限；伦理风险还取决于系统怎样被使用、谁受到伤害、谁负责纠错。 / Lack of interpretability is a distinct limit on trustworthiness; ethical risk also depends on how a system is used, who is harmed, and who is responsible for correction.

第 4 次：奖励与决策（第 8 章）

Rosie 的 Q-learning

关键句 / Key statement： Q 值估计在某状态采取某动作后，未来能获得多少回报，而不只是眼前的奖励。 / A Q-value estimates the future return from taking an action in a state, not just its immediate reward.

与监督学习的区别： 监督学习在训练时给出每个例子的正确标签；Rosie 不会在每一步都得到“正确动作”的答案。她采取动作后，只有成功踢中球才获得奖励。奖励是程序使用的数值信号，不是机器人真的感到开心。

1. 状态（state）、动作（action）、奖励（reward）： 书中简化了环境：状态只表示 Rosie 离球还有几步；动作只有前进、后退、踢球；踢中球获得奖励 10。一次训练从随机起点开始，到踢中球结束，称为一轮（episode）。
2. Q 表（Q-table）记录什么： 每一行是一个状态，每一列是一个可选动作。格子里的 Q 值（Q-value）是 Rosie 当前对“在这个状态做这个动作，之后继续合理行动，最终能得到

多少奖励”的估计。它不是这个动作立刻得到的奖励，也不是该动作永远正确的保证。起初各格设为 0，代表还没学到有用信息，不代表这些动作已经被证明没有价值。

3. 第一次获得奖励： Rosie 一开始随机尝试，可能倒退，也可能远离球时踢空。终于在离球 0 步时踢中，得到奖励 10；她先把“离球 0 步 → 踢球”记为高价值。此时她还不知道“离球 1 步 → 前进”也有价值。
4. 把价值传回前一步： 下一轮，当她在离球 1 步时碰巧前进，就到了已知“踢球很有价值”的状态。于是，“离球 1 步 → 前进”的 Q 值也提高；书中示意为 8，低于直接踢中时的 10。再往后的训练可让离球 2 步时的前进逐渐获得价值。越远离最终奖励，价值通常越要打折，这促使系统学习较短、有效的路径。
5. 探索与利用（exploration and exploitation）： 利用是选当前 Q 值最高的动作；探索是偶尔尝试尚不熟悉的动作。如果只利用，Rosie 可能永远发现不了更好的路径；如果一直探索，又会反复做无效动作。训练需要在两者之间取得平衡。

状态	动作	学到的 Q 值示意	为什么
离球 0 步	踢球	10	直接踢中，立刻获得奖励。
离球 1 步	前进	8	到达下一步可以踢中球的状态。
其他尚未学过的组合	任一动作	初始为 0	暂无证据，不等于动作一定无用。

现实中的困难： 真实机器人无法总是准确知道离球几步，动作后果也可能不确定；状态多到无法列成小小的 Q 表。复杂任务常让神经网络估计动作价值，并在模拟环境中大量训练，但模拟里学到的策略还要检验能否迁移到真实世界。

第 8 章：Rosie 学踢球

Rosie 的状态、动作和奖励分别是什么？她的 Q 表记录的是即时奖励，还是未来奖励的估计？请用“离球 0 步踢球”和“离球 1 步前进”解释奖励怎样逐步传回先前的动作，并说明探索与利用为什么都需要。最后指出将这种学习用于真实机器人的两个困难。

作答核心句 / Answer focus： 奖励可以使较早的状态与动作逐步获得更高的 Q 值。 / Rewards can gradually increase the Q-values of earlier state-action pairs.

参考答案

Rosie 的状态是她估计自己离球还有几步；动作是前进、后退或踢球；只有踢中球才得到数值奖励 10。Q 表为每个“状态 + 动作”记录未来奖励的估计，并非只记录立刻拿到多少奖励。起初各格为 0，她随机尝试；第一次在离球 0 步时踢中，先提高“0 步 → 踢球”的价值。下一轮在离球 1 步时前进，到达已经知道能踢中球的位置，于是“1 步 → 前进”也获得较高价值，书中的示意值是 8。之后价值可以继续逐步传回更早的状态，离最终奖励越远通常越要打折。探索是尝试可能更好的未知动作；利用是选择目前价值最高的动作。只利用可能错过更好策略，只探索则效率低。Rosie 的状态和动作被高度简化；真实机器人感知和行动结果不确定、状态空间巨大，Q 表难以列全，模拟训练也可能难以迁移。通过结果反馈改进行为与行为主义有历史联系，但 Q-learning 是具体的计算方法。

关键句 / Key statement： Q-learning 让未来奖励逐步影响较早的状态与动作选择。 / Q-learning lets future rewards gradually influence earlier state-action choices.

延伸：AlphaGo

围绕书中的三个要素——卷积神经网络、蒙特卡洛树搜索、强化学习——解释 AlphaGo 怎样获得类似“棋感”的快速估计、怎样选择和检验落点、又怎样通过自我对弈变强。AlphaGo Lee 和 AlphaGo Zero 在是否依赖人类棋谱方面有什么区别？Zero 好在哪里，为什么这仍不等于通用智能?

作答核心句 / Answer focus： 网络提出初步落点，搜索改进选择，强化学习通过自我对弈持续训练网络。 / The network proposes moves, search improves the choice, and reinforcement learning trains the network through self-play.

参考答案

书中把 AlphaGo 的核心组合概括为强化学习（reinforcement learning）、卷积神经网络（convolutional neural networks / CNNs）和蒙特卡洛树搜索（Monte Carlo tree search / MCTS），另有强大的计算硬件支持。三者各有分工，又形成反馈循环：

1. 卷积神经网络（CNN）提供类似“棋感”（intuition）的快速估计。 人类高手凭长期对局经验，看到棋形就能迅速判断值得考虑的落点。网络通过训练从棋盘局面学习模式，给候选落点和胜算提供初步估计。这里的“直觉”是计算上的类比，不证明它像人一样理解围棋。

2. 蒙特卡洛树搜索（MCTS）有选择地推演。 围棋的后续变化无法穷举；网络给搜索提供有希望的方向，搜索模拟部分可能的后续，记录胜负结果，形成比最初估计更有依据的落子选择。搜索既利用现有高分候选，也探索证据不足的走法。

3. 强化学习（reinforcement learning）通过自我对弈（self-play）改进判断。 系统反复对弈，用胜负反馈及搜索后改进的落点估计训练网络；网络变好后，又能给下一轮搜索更

好的起点。书中讲解这一循环时，主要以 AlphaGo Zero 为例。

关键句 / Key statement： 网络提供初步“棋感”，搜索改进落子，强化学习借自我对弈让网络不断变强。 / The network supplies an initial intuition, search improves move choices, and reinforcement learning strengthens the network through self-play.

版本区别与 Zero 的进步： 2016 年击败李世石的 AlphaGo Lee 还使用人类棋谱的监督学习与围棋专门知识。后来的 AlphaGo Zero 从围棋规则出发，不使用人类棋谱或预先编写的围棋专门知识，靠自我对弈让上述三者形成学习循环。书中记载，Zero 与 Lee 版本对弈 100 局全胜：它对人类棋谱依赖更少，围棋水平却更高。Zero 仍需要明确规则、目标、训练和计算资源；围棋能力不会自动迁移到别的游戏或现实任务。AlphaZero 将同类方法用于国际象棋和将棋时，针对每种游戏仍须分别训练网络。

关键句 / Key statement： AlphaGo Zero 从围棋规则和自我对弈开始，不用人类棋谱，却击败了早期的 AlphaGo Lee；这仍是围棋专项能力。 / AlphaGo Zero started with the rules and self-play, without human game records, and defeated the earlier AlphaGo Lee; this remained a specialized Go ability.

抽查评分建议：每题 0-3 分

分数	表现
3	说明关键机制，引用书中例子，并指出结论边界。
2	抓住主旨，但机制、例子或局限缺一项。
1	只有零散术语或笼统判断，解释不完整。
0	未回答，或核心概念明显混淆。

来源与范围： 依据 Melanie Mitchell 的 Artificial Intelligence: A Guide for Thinking Humans 编写。抽查重点为第 1、2、6、7、8 章；延伸案例来自序章及第 3、5、9、11、12、13、14、15 章。具体实验条件和作者论证以原书对应章节为准。

第二部分：查阅资料

以下术语、章节归属与全书案例用于查证和选例；里程碑表不要求逐项背诵。

章节范围

章节	核心问题	学习重点
1. The Roots of Artificial Intelligence	AI 如何表示和解决问题?	符号规则、GPS、感知机、早期方法的局限
2. Neural Networks and the Ascent of Machine Learning	神经网络怎样从例子中学习?	权重、偏置、损失、梯度、反向传播、梯度下降、学习率
6. A Closer Look at Machines That Learn	高准确率是否等于理解?	长尾情况、捷径特征、鲁棒性、对抗样本
7. On Trustworthy and Ethical AI	怎样判断系统是否值得信任，谁承担错误的后果?	长尾风险、群体偏差、不可解释性、鲁棒性与攻击、隐私、问责及机器道德
8. Rewards for Robots	智能体怎样通过行动学习?	状态、动作、奖励、探索与利用、迁移难题

章节归属： CNN/ConvNet 与 ImageNet 是第 5 章内容；第 6 章进一步分析机器学习系统的表现和局限。RNN 与 word2vec 在第 11 章，神经机器翻译在第 12 章，AlphaGo 在第 9 章。它们作为全书里程碑补充，不列为五章抽查的必答内容。

核心术语速查 / Key terms

中文	English	中文	English
符号主义	symbolic AI	次符号主义	subsymbolic AI
连接主义	connectionism	行为主义	behaviorism
神经网络	neural network	卷积神经网络	convolutional neural network (CNN/ConvNet)
权重	weight	偏置	bias parameter
损失函数	loss function	梯度	gradient
反向传播	backpropagation	梯度下降	gradient descent
学习率	learning rate	监督学习	supervised learning
强化学习	reinforcement learning	自我对弈	self-play
状态	state	动作	action
奖励	reward	探索与利用	exploration and exploitation
Q 值	Q-value / action value	泛化	generalization
长尾情境	long-tail scenarios	捷径学习	shortcut learning
鲁棒性	robustness	对抗样本	adversarial examples
偏差	bias in data or outcomes	不可解释性	lack of interpretability / black-box problem
蒙特卡洛树搜索	Monte Carlo tree search (MCTS)	迁移学习	transfer learning

全书里程碑与案例

时期/章节	里程碑或案例	展示的进步与边界
1950	图灵提出“模仿游戏”，后来称为图灵测试。	用对话中能否辨别人机来讨论机器智能；表现受话题、评判者和测试设计影响。
1956	Dartmouth 研讨会。	AI 研究领域正式成形；逻辑、统计学习和脑启发方法并存。
1950s-60s	GPS 与符号 AI。	人把状态、目标、规则和操作写进程序，系统搜索明确问题的解；不会自动补齐规则外常识。
1950s-60s	Rosenblatt 的感知机。	展示从带标签例子调整权重和阈值的思路；单层感知机能表示的关系有限。
1960s-70s	Minsky 与 Papert 对感知机的分析；AI 冬天。	揭示单层感知机能力边界；过度承诺后研究资金和热情下降。不能简化成一本书单独终结神经网络。
1970s-80s	专家系统 MYCIN；多层网络与反向传播发展。	MYCIN 用人写医学规则辅助诊断并解释推理；规则维护和迁移困难。反向传播使多层网络更可训练。
1997	Deep Blue 击败国际象棋世界冠军 Kasparov。	搜索和专用硬件在特定任务上达到顶尖；不能做棋类以外的事。
2011	IBM Watson 赢得 Jeopardy!。	展示大规模信息检索和问答能力；仍受题型、知识来源和系统设定约束。
2012	Google Brain 的“猫”实验。	大量未标注 YouTube 视频帧让深度网络学到对猫脸有响应的特征；不代表它理解猫或世界。
2010-12	ImageNet 数据集与竞赛；AlexNet 在 2012 年获胜。	大型标注数据、GPU 和卷积网络共同推动图像分类。ImageNet 成绩只适用于具体数据与任务。
研究脉络	Hubel 与 Wiesel 的视觉研究、福岛的 neocognitron、LeCun 的 ConvNet。	局部感受野、共享结构适合图像；CNN/ConvNet 的重点章节是第 5 章。

时期/章节	里程碑或案例	展示的进步与边界
2013 起	AlexNet 等系统的对抗样本。	人几乎看不出的图像变化可能让模型高置信度误判；测试集准确率不等于鲁棒性。
2015-16	自动驾驶长尾案例：路面撒盐线；避让沙袋后与公交车碰撞。	罕见情况、其他道路使用者行为和常识难以穷举；需要超出常见测试样例的验证。
训练数据偏差	面部识别和图像标签中的群体差异。	数据代表性会影响分群错误率，模型偏差可能造成现实伤害。
第 5 章	ImageNet 标注依赖人类众包劳动。	数据集规模扩大推动模型进步，也提醒我们训练数据来自人的分类选择和社会环境。
第 6 章	长尾、捷径学习、过拟合、鲁棒性。	高分可能依赖偶然线索；改变背景、分布或输入形式后表现会下降。
第 7 章	Amazon Rekognition 与 ACLU 的国会议员测试；Show Your Work 的不可解释性讨论。	535 张照片中 28 人被错误匹配；错误中 21% 涉及非裔议员，而非裔议员约占国会 9%。须检查分群误差、隐私和错误代价；网络运算清单本身不能解释判断依据。
第 8 章	Rosie 机器人通过 Q-learning 学踢球。	在状态中选择动作，成功后获得奖励，逐步提高有用动作的价值；真实系统状态空间更大。
第 9 章 / 2016	AlphaGo Lee 击败 Lee Sedol。	人类棋谱的监督学习、自我对弈与围棋专门知识参与训练；卷积网络、蒙特卡洛树搜索和强化学习结合，攻克围棋专项任务。
第 9 章 / 2017	AlphaGo Zero 与 AlphaZero。	Zero 仅从围棋规则和自我对弈起步，书中记载它与 Lee 版本对弈 100 局全胜；AlphaZero 的方法另用于国际象棋和将棋，但每种游戏仍须分别训练网络。
第 11 章	RNN、LSTM 与 word2vec。	RNN 处理序列数据；LSTM 帮助保留较长上下文；word2vec 从上下文学习词向量，也会继承文本偏差。

时期/章节	里程碑或案例	展示的进步与边界
第 12 章 / 2016	神经机器翻译。	编码器-解码器和循环网络将一种语言的序列映射到另一种语言；流畅输出仍可能误解语境和细节。
第 13 章	SQuAD 阅读理解数据集与问答系统。	系统在给定文章中找答案；基准高分不能保证理解前提错误或掌握常识。
第 14-15 章	常识、Bongard 问题、Copycat 类比程序、Cyc。	凸显机器在意义、灵活抽象和类比推理上的困难；Cyc 项目尝试显式编码常识。
序章 / 第 16 章	EMI 按古典作曲家的风格创作；关于 AI 未来的争论。	风格模仿令人信服，但不自动证明意图、理解或创造性。预测要区分任务演示与通用智能。
第 7 章	阿西莫夫三定律与电车难题。	规则中的“不作为”和“伤害”也要解释；五人与一人的两难问题揭示价值冲突，但不能替代现实的风险评估、人工复核和问责机制。

贯穿全书的判断方法： 里程碑通常说明某个系统在一个定义好的任务上取得新成绩。判断能力能否泛化，还要看它能否迁移到新任务、处理陌生情境、暴露错误原因，以及由谁承担错误后果。

附录：原讲义尚未覆盖的 NOAI 初赛 B 区考点

本附录只补大纲缺项；上面的原有章节、里程碑、学生题目和教师答案保留。以下内容并非全部出自 Mitchell 的书。NOAI 2026 大纲 B 区要求理解 AI 基础概念；A 区 Python 与 C/D 区实践另行准备。

1. 机器学习范式、任务与模型

考点	学生需要讲清楚的区别
训练与推理	训练用已有数据调整参数；推理用训练后的模型处理新输入。
监督与无监督学习	监督学习有目标标签，如根据房屋特征预测价格；无监督学习不提供目标标签，如根据相似性给顾客分组。强化学习的动作通过环境奖励反馈，参见原讲义 Rosie。
回归、分类、聚类	回归预测连续数值（房价），分类预测类别（患病与否），聚类发现相似样本的分组。常见方法分别有线性回归、逻辑回归或决策树、k-means。
线性与非线性	线性模型以输入的加权组合形成直线或平面关系；非线性方法能表达弯曲、复杂的关系。线性回归预测数值；逻辑回归把加权结果变为类别概率，通常用于分类。

大纲也要求能在题目提供第三方库调用方法时，尝试完成简单的机器学习任务；这属于 B 区应用要求，Python 基础语法在 A 区学习。

2. 数据、数学与评价

考点	关键点
数据清洗	检查缺失、重复、格式错误和异常值，按任务决定修正、填补或删除；不要让测试集信息进入训练过程。
训练、验证、测试集	训练集用于学习参数，验证集用于选模型和调整设置，测试集用于最后评估。交叉验证让训练数据轮流充当验证部分，减少单次划分的偶然性。
概率、正态分布、统计与距离	概率描述事件发生的可能性；正态分布呈中间多、两端少的钟形；均值看中心、标准差看分散，距离度量样本相似程度。不是所有数据都服从正态分布。
残差与偏差	残差是一次预测值与真实值的差；统计偏差是系统性偏离，数据偏差也可能指群体代表性不足。它们与神经网络的偏置参数不是同一个概念。
欠拟合、过拟合、正则化	模型过于简单，训练和验证都差是欠拟合；训练好、验证差是过拟合迹象。正则化约束复杂度，过强也可能造成欠拟合。
集成学习	组合多个模型。Bagging 对不同抽样数据训练模型并汇总，随机森林组合多棵随机化决策树；梯度提升依次训练新模型修正已有模型的错误。

混淆矩阵：先规定“阳性”的含义。 下例阳性表示患病。

实际情况 / 模型判断	判阳性	判阴性
患病	TP：找对	FN：漏诊
未患病	FP：误报	TN：正确排除

指标	关心什么	计算
准确率 Accuracy	所有人中判对的比例	(TP + TN) / 总人数
精确率 Precision	判为阳性的人中有多少真阳性	TP / (TP + FP)

指标	关心什么	计算
召回率 Recall，又称敏感性 Sensitivity	真阳性中找出多少	TP / (TP + FN)
F1 分数	综合精确率与召回率	2 × Precision × Recall / (Precision + Recall)
特异性 Specificity（辅助辨析）	真阴性中正确排除多少	TN / (TN + FP)

NOAI B 区点名准确率、精确率、召回率、F1 与交叉验证；特异性用于辨析漏诊和误报。例：20 位患者找出 16 位，80 位健康者误报 8 位，则 TP=16、FN=4、FP=8、TN=72。精确率=16/24≈0.667，召回率=16/20=0.8，特异性=72/80=0.9，准确率=88/100=0.88，F1≈0.727。漏诊严重时更关注召回率；误报代价高时关注精确率及假阳性。类别极不平衡时不能只看准确率。

3. 神经网络原讲义之外的 B 区点

考点	一句话解释
决策函数与激活函数	决策函数将输入映射为用于判断的分数或输出；激活函数给神经元带来非线性，损失函数衡量预测误差。原讲义已解释损失、反向传播、梯度下降和学习率。
局部与全局最优	局部最优是在附近找不到更好点，全局最优是在整个搜索范围最好；训练未必达到全局最优。
CNN 与三类层	卷积层以共享滤镜提取局部特征，池化层汇总邻近信息并缩小表示，全连接层综合特征输出判断。可用“图像→卷积与激活→池化→全连接→输出”解释典型结构。原讲义的 AlexNet 是应用例子。
动量优化、Adam 与 AdamW	普通梯度下降依当前梯度更新；动量考虑过去的更新方向，Adam 还自适应调整不同参数的步幅，AdamW 将权重衰减独立处理。B 区理解核心思路即可。
大语言模型 LLM	从大量文本的 token 上下文关系中学习，常借预测后续 token 等训练任务形成生成和问答能力；流畅输出不保证事实正确。部署及 API 实践属于第二轮。

补充自测与参考答案

1. 任务判断： 房价预测、疾病筛查、无标签顾客分组分别是回归、分类还是聚类？答案： 回归、分类、聚类。前两者可用带标签数据做监督学习，第三者通常属无监督学习。
2. 指标计算： 用上面的 100 人例子计算精确率、召回率和特异性，并分别说清分母是谁。答案： 16/24≈0.667（预测阳性）、16/20=0.8（实际阳性）、72/80=0.9（实际阴性）。
3. 训练诊断： 训练成绩很好，验证成绩差，可能是什么问题？答案： 过拟合迹象；应核查数据划分与泄漏，使用交叉验证、适当正则化，并在最后用独立测试集评价。
4. 神经网络结构： CNN 的卷积、池化、全连接层分别做什么？答案： 提取局部特征、汇总并缩小表示、综合特征形成最终判断。激活函数使网络能表示非线性关系。

依据： NOAI 2026 学术大纲 V1.5，B. 人工智能基础知识。