



更好的问题
更好的 AI

Better Questions
Better AI

第 1 页 / Page 1

机器学习任务识别流程

Machine Learning Task Identification Process

Ask
Analyze
Identify
Solve

让 AI 为更美好的
明天服务！
Use AI for a
Brighter Tomorrow!

从真实问题到正确的机器学习任务

From Real-World Problems to the Right ML Task

1

输入
Input



我有什么数据？
What data do I have?

- 特征（如文本、图像、数字等）
Features (e.g., text, images, numbers)
- 样本 / 记录
Records / samples
- 各种信号
Signals (e.g., click, sensor, transaction)

2

输出
Output



模型最终要预测 / 产生什么？
What should the model produce?

- 类别
A category (e.g., spam or not)
- 数值
A number (e.g., price, score)
- 分组 / 排名
A group or ranking (e.g., similar users, top 10 items)

3

标签
Label



历史数据中有没有正确答案？
Do historical examples have ground-truth labels?

- 有 / 没有
Yes / No
- 人工标注的标签
Manually labeled (e.g., by humans)
- 自然产生的目标
Naturally observed targets (e.g., purchase, click, defect)

4

任务类型
Task Type



这属于哪类机器学习任务？
Which machine learning task is this?

- 分类
Classification
- 回归
Regression
- 聚类
Clustering
- 异常检测
Anomaly Detection
- 降维
Dimensionality Reduction

5

最简单的基线
Baseline



先用什么简单方法做对比？
What is the simplest reasonable baseline?

- 逻辑回归
Logistic Regression (用于分类)
(for classification)
- 线性回归
Linear Regression (用于回归)
(for regression)
- K 均值
K-means (用于聚类)
(for clustering)
- 主成分分析 (PCA)
PCA (用于降维)
(for dimensionality reduction)



如何使用这套流程

How to Use This Process

1

先看**输出**。
Always look at the output first.

2

再看是否有**标签**。
Then check whether labels exist.

3

最后再选择**任务类型**和**基线**。
Only after that choose the task and baseline.



一句话例子

One-line Example



邮件特征
Email features



垃圾邮件 / 非垃圾邮件
Spam / Not Spam



有标签
Labels exist



分类
Classification



逻辑回归
Logistic Regression

邮件特征 → 垃圾邮件 / 非垃圾邮件 → 有标签 → 分类 → 逻辑回归
Email features → Spam / Not Spam → labels exist → Classification → Logistic Regression

先看**输出**，再看**标签**。

Look at the output first, then the labels.



更好的问题
更好的 AI

Better Questions
Better AI

第 2 页 / Page 2

常见任务类型详解 Common ML Tasks Explained

学会根据输出与标签判断任务
Identify tasks by output pattern and labels

Ask
Analyze
Identify
Solve

让 AI 为更美好的
明天服务！
Use AI for a
Brighter Tomorrow!

1 分类 Classification

将样本分到固定的类别中

Assign samples to predefined categories



分类问题

选择哪个类别？
Which category?

- 输出 Output 离散的类别标签 (如 A / B / C)
A discrete class label (e.g., A / B / C)
- 标签 Labels 有 Yes
- 典型场景 Typical examples 垃圾邮件检测、疾病诊断
Spam detection, disease diagnosis
- 最简单的基线 Simple baseline 逻辑回归 Logistic Regression
- 识别信号 Key clue 从固定的类别中选择
Choose from a fixed set of categories

2 回归 Regression

预测一个连续的数值

Predict a continuous numeric value



回归问题

预测多少？
What value?

- 输出 Output 连续的数值 (如价格、分数)
A continuous value (e.g., price, score)
- 标签 Labels 有 Yes
- 典型场景 Typical examples 房价预测、成绩/温度预测
House price prediction, score/temperature prediction
- 最简单的基线 Simple baseline 线性回归 Linear Regression
- 识别信号 Key clue 输出可以是任意数值
Output can take many numeric values

3 聚类 Clustering

将相似的样本自动分组

Group similar samples automatically



聚类问题

有哪些群组？
What groups?

- 输出 Output 相似样本的分组
Groups of similar samples
- 标签 Labels 没有 No
- 典型场景 Typical examples 客户分群、相似用户分组
Customer segmentation, grouping similar users
- 最简单的基线 Simple baseline K 均值 K-Means
- 识别信号 Key clue 没有预定义的标签，需要发现分组
No predefined labels, discover groups from data

4 异常检测 Anomaly Detection

找出异常或可疑的样本

Find abnormal or suspicious samples



异常检测问题

哪些是不正常的？
What is unusual?

- 输出 Output 正常或异常 (或异常分数)
Normal vs. abnormal (or an anomaly score)
- 标签 Labels 通常没有 Usually No
- 典型场景 Typical examples 欺诈检测、设备异常行为
Fraud detection, unusual equipment behavior
- 最简单的基线 Simple baseline 简单的异常值规则 或 孤立森林
Simple outlier rule or Isolation Forest
- 识别信号 Key clue 在大多数正常数据中找出少数异常
Find rare strange cases among mostly normal data

5 降维 Dimensionality Reduction

将高维数据映射到更低维的表示

Map high-dimensional data to a lower-dimensional representation



降维问题

如何用更少的特征？
How to use fewer features?

- 输出 Output 更低维的特征表示 (如 2D 或 10D)
A lower-dimensional representation (e.g., 2D or 10D)
- 标签 Labels 没有 No
- 典型场景 Typical examples 数据可视化、特征压缩
Data visualization, feature compression
- 最简单的基线 Simple baseline 主成分分析 PCA
- 识别信号 Key clue 在保留重要信息的同时减少特征
Reduce features while keeping important information



一句话对比 One-line Comparison

- 1 有标签 + 类别输出 → 分类
Labels + category output → Classification
- 2 有标签 + 连续数值输出 → 回归
Labels + numeric output → Regression
- 3 无标签 + 自动分组 → 聚类
No labels + group similar samples → Clustering
- 4 通常无标签 + 找异常 → 异常检测
Usually no labels + find rare cases → Anomaly Detection
- 5 无标签 + 减少特征 → 降维
No labels + reduce features → Dimensionality Reduction



更好的问题

更好的 AI

Better Questions

Better AI

第 3 页 / Page 3

任务识别决策树

Task Identification Decision Tree

从问题描述一步步判断机器学习任务
A step-by-step path from scenario to task

Ask
Analyze
Identify
Solve

让 AI 为更美好的
明天服务！
Use AI for a
Brighter Tomorrow!



先看输出是什么？

What should the model output?



类别？

A category?

(例如：正常 / 异常)
(e.g., normal / abnormal)



连续数值？

A continuous number?

(例如：价格、评分)
(e.g., price, score)



自动分组？

Discover groups?

(例如：用户分群)
(e.g., customer groups)



寻找异常？

Find rare abnormal cases?

(例如：欺诈检测)
(e.g., fraud detection)



压缩特征？

Fewer features?

(例如：数据降维)
(e.g., reduce dimensions)

有历史正确答案吗？
Do labels exist?

有
Yes

没有
No



分类

Classification

预测离散类别
Predict a category label



聚类

Clustering

发现自然分组
Discover natural groups



回归

Regression

预测连续数值
Predict a continuous value



聚类

Clustering

发现数据模式
Explore data patterns



聚类

Clustering

发现数据的自然分组
Find natural groups in data



异常检测

Anomaly Detection

发现稀有的异常样本
Find rare and abnormal cases



降维

Dimensionality Reduction

用更少的特征表示数据
Represent data with fewer features



使用方法

How to Use It

1

先看**输出**是什么。

Look at what the model should output.

2

再检查是否有**历史正确答案**。

Then check whether labels exist.

3

最后根据结果**选择任务类型**。

Finally, choose the appropriate task type.



常见分叉提醒

Common Fork Reminders

1

“预测”不一定是**回归**。

“Predict” does not always mean regression.

2

数值也可以是**类别标签**。

Numbers can still be class labels.

3

没有标签不一定是**聚类**。

No labels does not automatically mean clustering.

4

关注**目标**，而不是**数据格式**。

Focus on the goal, not the data format.



小例子

Mini Example

示例：邮件垃圾分类

Example: Email spam detection



邮件特征

Email features



垃圾邮件 / 非垃圾邮件

Spam / Not Spam



有标签

Labels exist



分类

Classification



更好的问题
更好的 AI
Better Questions
Better AI

第 4 页 / Page 4

核心心法与常见误区

Key Takeaways and Common Mistakes

学会稳定判断，再逐步进入进阶

Master the basics first, then move to advanced thinking

Ask
Analyze
Identify
Solve

让 AI 为更美好的
明天服务！
Use AI for a
Brighter Tomorrow!



核心心法 Core Principles

- 1 先看**输出**，再看**标签**。
Look at the output first, then the labels.
- 2 **输出的形式**决定任务类型。
The output form determines the task.
- 3 有**标签**不等于一定是**分类**。
Labels do not always mean classification.
- 4 没有**标签**也**不一定**就是**聚类**。
No labels do not automatically mean clustering.
- 5 先有**简单基线**，再谈**复杂模型**。
Start with a simple baseline before complex models.



常见误区 Common Mistakes

- 1 看到 **predict** 就以为是**回归**。
Thinking every "predict" problem is regression.
- 2 看到**数字**就以为是**回归**。
Assuming numeric outputs must be regression.
- 3 **有数据**就当作有**标签**。
Assuming data means labels exist.
- 4 没有**标签**就**只会想到****聚类**。
Assuming unlabeled data means clustering only.
- 5 把**推荐问题**当成**普通分类**。
Treating recommendation like simple classification.
- 6 **一上来就选****复杂模型**。
Jumping to complex models too early.



五步回答模板 / 5-Step Answer Template

1



输入
Input

2



输出
Output

3



标签
Label

4



任务类型
Task

5



最简单的基线
Baseline



进阶再加
Add later



评价指标
Evaluation metric



数据划分
Data split



预处理
Preprocessing



基线局限
Baseline limitation



下一步改进
Next improvement



训练建议 / Training Advice

1

多练习不同场景的问题。
Mix different scenarios
and practice more.

2

完整写出思考过程，
而不仅仅是说出任务类型。
Explain the full reasoning
process, not just the task type.

3

坚持每天练习，
直到能够稳定识别。
Practice daily until
task identification
becomes stable.



同一个问题，**清晰的判断**，比**复杂模型**更重要。
For the same problem, clear task identification matters more than a complex model.